Практическая применимость проекта

AI-гид рассчитан на людей, которые гуляют по Москве самостоятельно, но хотят слышать рассказ о том, что интересно именно им: туристов, приехавших на один-два дня, и москвичей, которые изучают незнакомые районы. Групповая экскурсия привязана к программе, времени и цене, а аудиогиды и готовые маршруты (izi.TRAVEL, «Узнай Москву») в основном рассказывают всем одно и то же. В нашем гиде пользователь выбирает темы и время на прогулку, система подбирает места и порядок их обхода, а в каждой точке языковая модель собирает рассказ из фрагментов, которые относятся к выбранным темам.

Заказчиками могут быть туристические сервисы и городские порталы, которым нужно персонализировать маршруты, музеи и усадьбы, где один и тот же объект можно по-разному рассказывать разным посетителям, и гиды, которым нужно быстро подобрать материал для тематической экскурсии. Самостоятельную ценность имеет и подготовленная база: каталог объектов с идентификаторами Wikidata и координатами и корпус фрагментов, размеченных по 14 темам, где у каждого фрагмента сохранена ссылка на источник.

Прототип реализуем на открытых данных: уже собран корпус по 206 объектам, это 1978 разделов статей Википедии и 3727 фрагментов. Для работающего сервиса нужно решить несколько проблем.

- **Ошибки языковой модели (серьёзно).** Неверную дату или имя слушатель на месте не проверит. Поэтому рассказ строится только из найденных фрагментов с источником, а выборку готовых рассказов нужно проверять вручную.
- **Слабая разметка (серьёзно на текущем этапе).** Автоматические правила оставили без меток 41,6% фрагментов, а редкие темы, например наука и нумизматика, почти не представлены. Поэтому качество по темам пока сильно различается: в baseline F1 для религии 0,912, для истории 0,115.
- **Ошибки сопоставления объектов (средне).** При проверке нашлись четыре записи с координатами других городов, а «Музей иллюзий» сначала сопоставился с Кусковом. Рассказ о другом объекте вводит пользователя в заблуждение, поэтому каталог требует ручной проверки.
- **Устаревание данных (средне).** Исторические тексты меняются редко, а часы работы, реставрации и временные выставки меняются постоянно. Чтобы маршрут не вёл к закрытому музею, нужен оперативный источник и регулярное обновление.
- **Права на тексты (средне).** Тексты Википедии распространяются по лицензии CC BY-SA, которая требует указывать авторство. Материалы других проектов можно использовать только на их условиях.
- **Приватность (средне).** Геолокация и интересы пользователя относятся к персональным данным, их нужно хранить в минимальном объёме.
- **Этика (серьёзно на запуске).** Наши сложности: 1) надо общаться на чувствительные темы (история, религия), 2) используем внешние источники данных (там могут быть неверные/неэтичные материалы), 3) при коллаборации с государственными учреждениями возникнет много этических требований.

Надо подумать про: входную и выходную этику, пайплайн обновления корпуса статей.

Заказчик может оценивать качество на трёх уровнях. Классификатор тем проверяется по micro-F1 и macro-F1 на вручную размеченном тесте, где представлены все 14 тем. Текущий baseline на TF-IDF и логистической регрессии даёт micro-F1 0,630 и macro-F1 0,365 по слабым меткам и служит только ориентиром. Рассказы оцениваются по доле утверждений, подтверждённых источником, по числу фактических ошибок и по экспертной оценке соответствия выбранным темам. Для продукта важно, укладывается ли маршрут в заданное время и не включает ли закрытые объекты, какую часть маршрута пользователи проходят до конца и как оценивают рассказы. Удобнее всего сравнить персонализированный гид с обычным аудиогидом по тем же местам в A/B-тесте.

Даже если сервис не дойдёт до запуска, у проекта остаётся учебная ценность: воспроизводимый конвейер от открытых данных до корпуса со ссылками на источники и разделение выборки по объектам, которое показывает качество модели на местах, не встречавшихся при обучении. Этот подход можно перенести на другие города.